

Économétrie

Contents

I	Modèle linéaire simple	4
1	Introduction	4
1.1	Définition	4
1.2	Prix Nobels	4
2	Histoire de l'économétrie	4
2.1	Des Origines de l'économétrie à l'âge d'or de la modélisation Macro-économique . . .	4
2.1.1	Premières études [17eme 18eme siècle]	4
2.1.2	Genèse de l'économétrie [19 ^{ème} siècle]	4
2.1.3	Imbrication de l'économie, des mathématiques et de la statistique [20 ^{ème} siècle]	5
2.2	De la crise de la modélisation macro-économique à l'âge d'or de l'économétrie	6
2.2.1	Années 70 et la fin de l'âge d'or de la modélisation marco-économétrique selon la tradition de la Cowles Foundation	6
3	Le modèle linéaire simple à deux variables et généralisation a k variables	6
3.1	Les hypothèses de base du modèle	7
3.2	Les estimateurs des MCO (moindres carrés ordinaire)	8
4	Lois des estimateurs, intervalles de confiance et tests d'hypothèse	9
4.1	Estimation par intervalle de confiance	9
4.1.1	Intervalle de confiance de β	9
4.1.2	Intervalle de confiance de $\hat{\alpha}$	10
4.1.3	Intervalle de confiance de σ_ϵ^2	10
4.2	Tests d'hypothèse	11
4.2.1	Test de β	11
4.2.2	Test de α	12
4.2.3	Test de σ_ϵ^2	13
4.3	Étude de la corrélation	13
4.3.1	Propriétés	13
4.3.2	Analyse de la Variance	14
4.3.3	Calcul du coefficient de détermination R^2	15
4.3.4	Test du coefficient de corrélation linéaire r	15
4.3.5	Tableau de l'analyse de la variance	16
5	Test du coefficient de détermination R^2	16

6	Utilisation du modèle de régression en prévision	17
6.1	Intervalle de confiance : de la valeur moyenne de Y connaissant une valeur donnée de X	17
6.2	Tests d'hypothèse : comparaison d'une prévision ponctuelle à la droite des moindres carrés	18
7	Le modèle linéaire simple à plusieurs variables explicatives	20
7.1	Les estimateurs des moindres carrés ordinaires (MCO)	20
7.1.1	Spécifications matricielles du modèle	20
7.1.2	Les hypothèses de base du MLGS	20
7.1.3	Les estimateurs des moindres carrés ordinaires	20
7.1.4	Les propriétés des estimateurs des moindres carrés ordinaires	20
7.2	Test des estimateurs	20
7.3	L'analyse de la variance et test du coefficient de détermination	20
7.4	Utilisation du modèle en prévision	20
II	Modèle linéaire général à k paramètres estimés	20
8	Test de normalité	20
8.1	Test de symétrie normale (Skewness)	20
8.2	Test d'aplatissement normal (Kurtosis)	21
8.3	Test de Jarque-Bera	21
9	Le problème de l'autocorrélation des erreurs	22
9.1	Détection de l'autocorrélation	22
9.2	Causes de l'autocorrélation	22
9.3	Les effets de l'autocorrélation	22
9.4	Tests d'autocorrélation	23
9.4.1	Test d'autocorrélation d'ordre 1 (Durbin Watson)	23
9.4.2	Test d'autocorrélation d'ordre k	23
10	Le problème de l'hétéroscédasticité	24
10.1	Définition et conséquences	24
10.2	Test de Glejser	24
10.3	Test de ARCH	25
10.4	Test de Breusch Pagan	25
10.5	Test de White	25
10.6	Goldfeld - Quandt	26
11	La Multi-colinéarité	26
11.1	Définition	26
11.2	Les effets de la colinéarité	27
11.3	Les tests de colinéarité	27
11.3.1	Test d'Haitvosky	27
11.3.2	VIF	27

11.3.3	Etude des valeurs propres de la matrice des coefficients de corrélation linéaire simple \tilde{R}	28
11.4	Solutions aux violations des hypothèses de base	28
11.5	Robustesse du modèle	29
11.5.1	Test d'ANACOVA	29
11.5.2	Test de comparaison des coefficients de régression	29
11.5.3	Test de comparaison des coefficients de corrélation	30

III Bibliographie 30

Part I

Modèle linéaire simple

1 Introduction

1.1 Définition

L'économétrie est le domaine de l'économie qui s'occupe de l'application de la statistique mathématique et des outils de l'inférence statistique à la mesure empirique des relations postulées par la théorie économique.

1.2 Prix Nobels

1980, Laurence Klein : Modèles macro-économétriques et leurs applications a l'analyse des fluctuations économiques

1989, Trygve Haavelmo : Approche probabiliste et les modèles a équations simultanées

2000, James Heckman : Travaux sur les théories et méthodes d'analyse des échantillons sélectifs

2000, Mac Fadden : Économétrie des choix discrets

2003, Robert F. Engle : Volatilité des séries temporelles pour les modèles ARCH 2003, Clive Granger : Théorie de la cointégration

2 Histoire de l'économétrie

2.1 Des Origines de l'économétrie à l'âge d'or de la modélisation Macro-économique

2.1.1 Premières études [17eme 18eme siècle]

L'autorité de la loi naturelle se dégage de celle de la religion et du prince

Apparition des statistiques

Statistique Allemande

La Statistique est un moyen de classer les savoirs hétéroclites

Conring, Herman

Arithmétique Politique (Angleterre)

Utilisation de techniques statistiques pour le dépouillement des registres paroissiaux

Petty, William : études natalité/mortalité

King, Gregory : formalisation loi de demande

2.1.2 Genèse de l'économétrie [19^{ème} siècle]

La statistique mathématique et l'évolution probabiliste de multiples champs permet de donner une dimension statistique à la représentation de la société

Galton	Statistique mathématique et Analyse mathématique de la régression (corrélation)
Edgeworth	Fonction de densité de la loi normale multivariée. Détermine les expressions de coefficient de régression multiple
Pearson	Coefficient de corrélation multiple : Analyse de la relation entre variables
Yule	Paupérisme, relation avec les mesures d'assistance
Hocker	Utilisation de variables retardées
Lenoir	Première estimation des lois d'offre et demande
Moore	Problème de détermination des salaires, utilisation des corrélations multiples, auto-corrélation et corrélogrammes

Conjoncturistes Américains :

Juglar, Kitchin, Kondratieff

Analyse des cycles économiques \neq économie mathématique (Moore)

- Création d'instituts de conjecture (Russie 1920)
- Création du NBER (national bureau of economics research)

2.1.3 Imbrication de l'économie, des mathématiques et de la statistique [20^{ème} siècle]

A la fin des années 20, l'économétrie gagne de l'intérêt en Europe. Création de la société d'économétrie le 29/12/1930 à Cleveland avec Frish, Timbergen. Elle officialise l'économétrie comme discipline et nomme Fisher président. La société d'économétrie recrute Cowles, qui, en contre-partie, demande la création d'une revue (*Econometrica*, RC : Frish) et la création d'un organisme de recherche Cowles Foundation. Roos est nommé premier président de la Cowles foundation.

- Avant 1930 la théorie des probabilités est pratiquement inutilisée jusqu'à ce que Haavelmo propose d'y apporter une approche stochastique (aléatoire)
- Apparition d'une chaire d'économétrie
- Diversification des sources de financement par l'obtention de subventions (Rockefeller, NBER)
- Le terme d'identification apparaît après les travaux de Haavelmo

Tous ces travaux marquent le début de la modélisation macro-économique qui connaîtra son âge d'or dans les 60's - 70's avec Keynes et les comptes nationaux. Âge d'or de la modélisation macro-économique et essor des modèles dynamiques.

1. Introduction de mécanismes dynamiques dans les modèles économétriques
2. Modèles à retard échelonnés Koyck
3. Développement des prévisions à court terme Box & Jenkins

2.2 De la crise de la modélisation macro-économique à l'âge d'or de l'économétrie

2.2.1 Années 70 et la fin de l'âge d'or de la modélisation macro-économétrique selon la tradition de la Cowles Foundation

- Premier choc pétrolier → Remise en cause des modélisations
- **Sims** → Modèles VAR (*vector auto regressive*)
- Fonctions de réponse impulsionnelle
- Etude de la causalité
- Test de la racine unitaire (Si les séries sont stationnaires ou non)
- Apparition de la modélisation ARCH, instauration d'une économétrie plurielle (modèle logit, probit)
- Introduction des principes Baillisiens

3 Le modèle linéaire simple à deux variables et généralisation à k variables

Modèle économétrique : Représentation simplifiée mais la plus exhaustive possible d'une entité économique donnée sous sa forme la plus courante représentée par un système d'équation (souvent linéaire) et relie des types de variables similaires

Variables explicatives → Variables exogènes
Variables expliquées → Variables endogènes

$Y = f(X_1, X_2, \dots, X_n)$ une seule variable explicative Y et une expliquée X

$Y = \alpha + \beta X$ (α et β sont des paramètres inconnus). Cette relation est exacte, or cela est impossible en économie, on doit donc introduire un terme aléatoire (aléa ou erreur). cette variable a pour rôle de synthétiser l'ensemble des influences sur Y que X ne peut expliquer.

3 Types de modèles :

- Modèle en série chronologique (évolution au cours du temps)

$$Y_t = \alpha + \beta X_t + \varepsilon_t$$

- Modèle en coupe instantanée (à un moment donné dans le temps)

$$Y_i = \alpha + \beta X_i + U_i$$

- Modèle de panel

$$Y_{ti} = \alpha + \beta X_{ti} + U_{it}$$

Le fait d'introduire un aléa permet de faire des tests sur α et β .

Tout modèle non linéaire peut se ramener à un modèle linéaire (transformation par anamorphose).

Exemples (transformation)

$Y = \alpha e^{\beta X}$	$Y = \alpha X^\beta$	$Y = \frac{\alpha}{X^\beta}$
$\ln Y = \ln \alpha + \beta X$	$\ln Y = \ln \alpha + \beta X \ln$	$\ln Y = \ln \alpha - \beta \ln X$
$Y' = \alpha' + \beta X$	$Y' = \alpha' + \beta X'$	$Y' = \alpha' - \beta X'$

$$Y_t = \frac{Y_0}{1 + \beta X^t} \Leftrightarrow \frac{Y_0}{Y_t} - 1 = \beta X^t$$

$$\ln\left(\frac{Y_0}{Y_t} - 1\right) = \ln(\beta X^t) \Leftrightarrow \ln Y_0 - \ln Y_t = \ln \beta + t \ln X$$

$$Y' = \beta' + t X'$$

3.1 Les hypothèses de base du modèle

Il existe deux méthodes qui permettent d'estimer α et β

- Méthode des MCO (moindres carrés ordinaires)
- Méthode du maximum de vraisemblance

Hypothèses

- * X est une variable contrôlée (indépendante de l'aléa). $Cov(X, \varepsilon) = 0$
- * $\varepsilon \rightarrow$ une hypothèse de normalité. $E(\varepsilon_t) = 0$
En moyenne l'ensemble des facteurs non expliqués par la régression (qui se retrouvent dans l'aléa) tendent à se compenser.
- * Hypothèse d'homosédasticité :
la variance de ε_t est constante quel que soit le sous échantillon prélevé dans l'intervalle $\{1; n\}$
 $E(\varepsilon_t^2) = \sigma_t^2$
- * Hypothèse de non autocorrélation de l'aléa :
La distribution de ε_t qui correspond à X_t est indépendante de celle de $\varepsilon_{t'}$ qui correspond à $X_{t'}$
 $Cov(\varepsilon_t, \varepsilon_{t'}) = E(\varepsilon_t \varepsilon_{t'}) = 0 \quad (\forall t \neq t')$

3.2 Les estimateurs des MCO (moindres carrés ordinaire)

La méthode des MCO consiste à **minimiser la somme des carrés des écarts**. Écarts entre les valeurs observées de la variable Y_t et la valeur calculée de cette même variable \hat{Y}_t . Écart mesuré respectivement par les projections parallèlement à l'axe des ordonnées des points sur la droite de régression.

Programme de Minimisation :

$$\min \sum_t e_t^2 = \min \sum_t (Y_t - \hat{Y}_t)^2 = \min \sum_t (Y_t - (\hat{\alpha} + \hat{\beta} X_t))^2$$

Conditions de premier ordre :

$$\begin{array}{lcl} \frac{\partial \varphi}{\partial \hat{\alpha}} = 0 & & \frac{\partial \varphi}{\partial \hat{\beta}} = 0 \\ \Leftrightarrow -2 \sum_t (Y_t - \hat{\alpha} - \hat{\beta} X_t) = 0 & \Leftrightarrow -2 \sum_t (Y_t - \hat{\alpha} - \hat{\beta} X_t) X_t = 0 & \\ \Leftrightarrow n\bar{Y} - n\hat{\alpha} - \hat{\beta} n\bar{X} = 0 & \Leftrightarrow \sum_t (Y_t - (\bar{Y} - \hat{\beta}\bar{X} - \hat{\beta} X_t)) X_t = 0 & \\ \Leftrightarrow \hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X} & \Leftrightarrow \sum_t X_t Y_t - \bar{Y} \sum_t X_t + \hat{\beta} \bar{X} \sum_t X_t - \hat{\beta} \sum_t X_t^2 = 0 & \\ & \Leftrightarrow \sum_t X_t Y_t - \bar{Y} n\bar{X} + \hat{\beta} \bar{X} n\bar{X} - \hat{\beta} \sum_t X_t^2 = 0 & \\ & \Leftrightarrow \sum_t X_t Y_t - n\bar{X}\bar{Y} - \hat{\beta} (\sum_t X_t^2 - n\bar{X}^2) = 0 & \\ & \Leftrightarrow \hat{\beta} = \frac{\sum_t X_t Y_t - n\bar{X}\bar{Y}}{\sum_t X_t^2 - n\bar{X}^2} = \frac{n \text{Cov}(X, Y)}{nV(X)} & \end{array}$$

D'où

$$\begin{aligned} \hat{\beta} &= \frac{\sum_t (X_t - \bar{X}) (Y_t - \bar{Y})}{\sum_t (X_t - \bar{X})^2} = \frac{\sum_t X_t Y_t - n\bar{X}\bar{Y}}{\sum_t X_t^2 - n\bar{X}^2} = \frac{n \cdot \text{Cov}(X, Y)}{n \cdot V(X)} \\ \hat{\alpha} &= \bar{Y} - \hat{\beta}\bar{X} \end{aligned}$$

Conditions de second ordre :

$$\begin{aligned} \frac{\partial^2 \varphi}{\partial \hat{\alpha}^2} &= 2 > 0 \\ \frac{\partial^2 \varphi}{\partial \hat{\beta}^2} &= 2 > 0 \end{aligned}$$

La fonction est convexe, on a donc bien un minimum

La droite de régression passe par le point moyen qui est le centre de gravité (couple \bar{X}, \bar{Y}).
Données centrées :

$$\begin{aligned} x_t &= X_t - \bar{X} & \hat{y}_t &= \hat{Y}_t - \bar{Y} \\ y_t &= Y_t - \bar{Y} & \hat{x}_t &= \hat{X}_t - \bar{Y} \end{aligned}$$

On cherche \hat{y} :

$$\hat{Y}_t = \hat{y}_t + \bar{Y} = \hat{\alpha} + \hat{\beta}X_t = \hat{\alpha} + \hat{\beta}(x_t + \bar{X})$$

$$\begin{aligned} \hat{y}_t &= -\bar{Y} + \hat{\alpha} + \hat{\beta}x_t + \hat{\beta}\bar{X} \\ &= -\bar{Y} + \hat{\beta}x_t + \hat{\beta}\bar{X} + (\bar{Y} - \hat{\beta}\bar{X}) \\ \hat{y}_t &= \hat{\beta}x_t \end{aligned}$$

4 Lois des estimateurs, intervalles de confiance et tests d'hypothèse

Comme les estimateurs sont linéaires de Y_t et comme Y_t dépend de ε_t et que ε_t est aléatoire et qu'il obéit à une loi normale, alors les estimateurs sont donc aléatoires et obéissent à une loi normale.

$$\hat{\alpha} \sim N\left(\alpha, \sigma_\varepsilon \sqrt{\frac{\sum X_t^2}{n \sum x_t^2}}\right) \quad \hat{\beta} \sim N\left(\beta, \sigma_\varepsilon \sqrt{\frac{1}{\sum_{t=1}^n x_t^2}}\right)$$

$$(n-2) \frac{\hat{\sigma}_\varepsilon^2}{\sigma_\varepsilon^2} \sim \chi^2(n-2)$$

4.1 Estimation par intervalle de confiance

4.1.1 Intervalle de confiance de β

$$\exists \beta_1, \beta_2 / 1 - \alpha = Prob[\beta_1 < \beta < \beta_2]$$

$$\frac{\frac{\hat{\beta} - \beta}{\sigma_\varepsilon / \sqrt{\sum_{t=1}^n x_t^2}}}{\sqrt{(n-2) \cdot \frac{\hat{\sigma}_\varepsilon^2}{\sigma_\varepsilon^2} \cdot \frac{1}{(n-2)}}} \sim T(n-2) \quad \Leftrightarrow \quad \frac{\hat{\beta} - \beta}{\hat{\sigma}_\varepsilon} \cdot \sqrt{\sum x_t^2} \sim T(n-2)$$

d'où :

$$\begin{aligned}
1 - \alpha &= \text{Prob} [t_{\alpha/2} < T(n-2) < t_{1-\alpha/2}] \\
&= \text{Prob} \left[t_{\alpha/2} < \frac{\hat{\beta} - \beta}{\hat{\sigma}_\varepsilon} \cdot \sqrt{\sum x_t^2} < t_{1-\alpha/2} \right] \\
&= \text{Prob} \left[t_{\alpha/2} \cdot \frac{\hat{\sigma}_\varepsilon}{\sqrt{\sum x_t^2}} < \hat{\beta} - \beta < t_{1-\alpha/2} \cdot \frac{\hat{\sigma}_\varepsilon}{\sqrt{\sum x_t^2}} \right] \\
&= \text{Prob} \left[\hat{\beta} - t_{1-\alpha/2} \cdot \frac{\hat{\sigma}_\varepsilon}{\sqrt{\sum x_t^2}} < \beta < \hat{\beta} - t_{\alpha/2} \cdot \frac{\hat{\sigma}_\varepsilon}{\sqrt{\sum x_t^2}} \right] \\
&= \text{Prob} \left[\beta \in \left[\hat{\beta} \pm \left\{ \begin{array}{c} t_{\alpha/2} \\ t_{1-\alpha/2} \end{array} \frac{\hat{\sigma}_\varepsilon}{\sqrt{\sum x_t^2}} \right\} \right] \right]
\end{aligned}$$

4.1.2 Intervalle de confiance de $\hat{\alpha}$

$$\exists \alpha_1, \alpha_2 / 1 - \alpha = \text{Prob}[\alpha_1 < \alpha < \alpha_2]$$

$$\frac{\frac{\hat{\alpha} - \alpha}{\sigma_\varepsilon / \sqrt{\frac{\sum x_t^2}{n \sum x_t^2}}}}{\sqrt{\frac{(n-2)}{n-2} \cdot \frac{\hat{\sigma}_\varepsilon^2}{\sigma_\varepsilon^2}}} \sim T(n-2) \quad \Leftrightarrow \quad \frac{\hat{\alpha} - \alpha}{\hat{\sigma}_\varepsilon} \cdot \frac{\sqrt{n \sum x_t^2}}{\sqrt{\sum X_t^2}} \sim T(n-2)$$

d'où :

$$\begin{aligned}
1 - \alpha &= \text{Prob} [t_{\alpha/2} < T(n-2) < t_{1-\alpha/2}] \\
&= \text{Prob} \left[t_{\alpha/2} < \frac{\hat{\alpha} - \alpha}{\hat{\sigma}_\varepsilon} \cdot \frac{\sqrt{n \sum x_t^2}}{\sqrt{\sum X_t^2}} < t_{1-\alpha/2} \right] \\
&= \text{Prob} \left[t_{\alpha/2} \cdot \hat{\sigma}_\varepsilon \frac{\sqrt{\sum X_t^2}}{\sqrt{n \sum x_t^2}} < \hat{\alpha} - \alpha < t_{1-\alpha/2} \cdot \hat{\sigma}_\varepsilon \frac{\sqrt{\sum X_t^2}}{\sqrt{n \sum x_t^2}} \right] \\
&= \text{Prob} \left[\hat{\alpha} - t_{1-\alpha/2} \cdot \hat{\sigma}_\varepsilon \frac{\sqrt{\sum X_t^2}}{\sqrt{n \sum x_t^2}} < \alpha < \hat{\alpha} - t_{\alpha/2} \cdot \hat{\sigma}_\varepsilon \frac{\sqrt{\sum X_t^2}}{\sqrt{n \sum x_t^2}} \right] \\
&= \text{Prob} \left[\alpha \in \left[\hat{\alpha} \pm \left\{ \begin{array}{c} t_{\alpha/2} \\ t_{1-\alpha/2} \end{array} \hat{\sigma}_\varepsilon \frac{\sqrt{\sum X_t^2}}{\sqrt{n \sum x_t^2}} \right\} \right] \right]
\end{aligned}$$

4.1.3 Intervalle de confiance de σ_ε^2

$$\exists \sigma_1^2, \sigma_2^2 / 1 - \alpha = \text{Prob} [\sigma_1^2 < \sigma_\varepsilon^2 < \sigma_2^2]$$

$$(n-2) \cdot \frac{\hat{\sigma}_\varepsilon^2}{\sigma_\varepsilon^2} \sim \chi^2(n-2)$$

d'où

$$\begin{aligned}
1 - \alpha &= Prob \left[\chi_{\alpha/2}^2 < \chi^2(n-2) < \chi_{1-\alpha/2}^2 \right] \\
&= Prob \left[\chi_{\alpha/2}^2 < (n-2) \cdot \frac{\hat{\sigma}_\varepsilon^2}{\sigma_\varepsilon^2} < \chi_{1-\alpha/2}^2 \right] \\
&= Prob \left[\frac{\chi_{\alpha/2}^2}{(n-2)\hat{\sigma}_\varepsilon^2} < \frac{1}{\sigma_\varepsilon^2} < \frac{\chi_{1-\alpha/2}^2}{(n-2)\hat{\sigma}_\varepsilon^2} \right] \\
&= Prob \left[\frac{(n-2)\hat{\sigma}_\varepsilon^2}{\chi_{1-\alpha/2}^2} < \sigma_\varepsilon^2 < \frac{(n-2)\hat{\sigma}_\varepsilon^2}{\chi_{\alpha/2}^2} \right]
\end{aligned}$$

4.2 Tests d'hypothèse

4.2.1 Test de β

Spécification du test

$$H_0 : \beta = 0 \quad H_1 : \beta \neq 0$$

Statistique de test

$$\frac{\hat{\beta} - \beta}{\hat{\sigma}_\varepsilon} \cdot \sqrt{\sum x_t^2} \sim T(n-2)$$

Intervalle d'acceptation

$$\begin{aligned}
1 - \alpha &= Prob \left[t_{\alpha/2} < T(n-2) < t_{1-\alpha/2} \right] \\
&= Prob \left[t_{\alpha/2} < \frac{\hat{\beta}}{\hat{\sigma}_\varepsilon} \cdot \sqrt{\sum x_t^2} < t_{1-\alpha/2} \right] \text{ si } H_0 \text{ vrai} \\
&= Prob \left[t_{\alpha/2} \cdot \frac{\hat{\sigma}_\varepsilon}{\sqrt{\sum x_t^2}} < \hat{\beta} < t_{1-\alpha/2} \cdot \frac{\hat{\sigma}_\varepsilon}{\sqrt{\sum x_t^2}} \right] \\
&= Prob \left[\hat{\beta} \in \left[\pm t_{\alpha/2} \frac{\hat{\sigma}_\varepsilon}{\sqrt{\sum x_t^2}} \right] \right] \text{ IA}
\end{aligned}$$

RDD

Si $\hat{\beta} \in \text{IA}$ on accepte H_0 au risque de première espèce α

Si $\hat{\beta} \notin \text{IA}$ on rejette H_0 au risque de première espèce α (validité du modèle)

Autre façon de procéder

$$\begin{aligned} 1 - \alpha &= Prob \left[t_{\alpha/2} < \frac{\hat{\beta}}{\hat{\sigma}_\varepsilon / \sqrt{\sum x_t^2}} < t_{1-\alpha/2} \right] = Prob \left[\left| \frac{\hat{\beta}}{\hat{\sigma}_\varepsilon / \sqrt{\sum x_t^2}} \right| < t_{1-\alpha/2} \right] \\ &= Prob \left[\left| \frac{\hat{\beta}}{\hat{\sigma}_{\hat{\beta}}} \right| < t_{1-\alpha/2} \right] \\ &= Prob \left[|t_c| < t_{1-\alpha/2} \right] \end{aligned}$$

$$\text{Avec } t_c = \frac{\hat{\beta}}{\hat{\sigma}_{\hat{\beta}}} \sim T(n-2)$$

RDD

Si $|t_c| < t_{1-\alpha/2}$ on accepte H_0 au risque de α

Si $|t_c| \geq t_{1-\alpha/2}$ on rejette H_0 au risque de α

4.2.2 Test de α

Spécification du test

$$H_0 : \alpha = 0 \quad H_1 : \alpha \neq 0$$

Statistique de test

$$\frac{\hat{\alpha} - \alpha}{\hat{\sigma}_\varepsilon} \cdot \frac{\sqrt{n \sum x_t^2}}{\sqrt{\sum X_t^2}} \sim T(n-2)$$

Intervalle d'acceptation

$$\begin{aligned} 1 - \alpha &= Prob \left[t_{\alpha/2} < T(n-2) < t_{1-\alpha/2} \right] \\ &= Prob \left[t_{\alpha/2} < \frac{\hat{\alpha}}{\hat{\sigma}_\varepsilon} \cdot \frac{\sqrt{n \sum x_t^2}}{\sqrt{\sum X_t^2}} < t_{1-\alpha/2} \right] \text{ si } H_0 \text{ vrai} \\ &= Prob \left[t_{\alpha/2} \cdot \hat{\sigma}_\varepsilon \frac{\sqrt{\sum X_t^2}}{\sqrt{n \sum x_t^2}} < \hat{\alpha} < t_{1-\alpha/2} \cdot \hat{\sigma}_\varepsilon \frac{\sqrt{\sum X_t^2}}{\sqrt{n \sum x_t^2}} \right] \\ &= Prob \left[\hat{\alpha} \in \left[\pm t_{\alpha/2} \cdot \hat{\sigma}_\varepsilon \frac{\sqrt{\sum X_t^2}}{\sqrt{n \sum x_t^2}} \right] \right] \text{ IA} \end{aligned}$$

RDD

Si $\hat{\alpha} \in \text{IA}$ on accepte H_0 au risque de première espèce α

Si $\hat{\alpha} \notin \text{IA}$ on rejette H_0 au risque de première espèce α

Autre façon de procéder

$$t_c = \frac{\hat{\alpha}}{\hat{\sigma}_{\hat{\alpha}}} \sim T(n-2)$$

RDD

Si $|t_c| < t_{1-\alpha/2}$ on accepte H_0 au risque de α

Si $|t_c| \geq t_{1-\alpha/2}$ on rejette H_0 au risque de α

4.2.3 Test de σ_ε^2

Spécification du test

$$H_0 : \sigma_\varepsilon^2 = \sigma_0^2 \quad H_1 : \sigma_\varepsilon^2 \neq \sigma_0^2$$

Statistique de test

$$(n-2) \frac{\hat{\sigma}_\varepsilon^2}{\sigma_0^2} \sim \chi^2(n-2)$$

Intervalle d'acceptation

$$\begin{aligned} 1 - \alpha &= \text{Prob} \left[\chi_{\alpha/2}^2 < \chi^2(n-2) < \chi_{1-\alpha/2}^2 \right] \\ &= \text{Prob} \left[\chi_{\alpha/2}^2 < (n-2) \cdot \frac{\hat{\sigma}_\varepsilon^2}{\sigma_0^2} < \chi_{1-\alpha/2}^2 \right] \text{ si } H_0 \text{ vrai} \\ &= \text{Prob} \left[\chi_{\alpha/2}^2 \cdot \frac{\sigma_0^2}{n-2} < \sigma_\varepsilon^2 < \chi_{1-\alpha/2}^2 \cdot \frac{\sigma_0^2}{n-2} \right] \end{aligned}$$

RDD

Si $\sigma_\varepsilon^2 \in \text{IA}$ on accepte H_0 au risque de première espèce α

Si $\sigma_\varepsilon^2 \notin \text{IA}$ on rejette H_0 au risque de première espèce α

4.3 Étude de la corrélation

Le **coefficient de corrélation** est un coefficient qui mesure le degré de covariation linéaire, c'est à dire la manière dont varient ensemble les variables entre elles.

$$r_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \cdot \sigma_Y} = \frac{\sum x_t y_t}{\sqrt{\sum x_t^2 \sum y_t^2}}$$

4.3.1 Propriétés

- $-1 \leq r \leq 1$
- r est sans dimension
- r est symétrique : $r_{XY} = r_{YX}$
- r n'est pas affecté par un changement de variable $r_{XY} = r_{xy}$ avec $r_{xy} = \frac{\sum x_t y_t}{\sqrt{\sum x_t^2 \sum y_t^2}}$
- Relation entre $\hat{\beta}$ et r : $\hat{\beta} = \frac{\sum x_t y_t}{\sum x_t^2}$

$$r = \hat{\beta} \cdot \frac{\sqrt{\sum x_t^2}}{\sqrt{\sum y_t^2}} \Leftrightarrow r = \hat{\beta} \frac{\sqrt{\frac{1}{n} \sum (X_t - \bar{X})^2}}{\sqrt{\frac{1}{n} \sum (Y_t - \bar{Y})^2}} \Leftrightarrow r = \hat{\beta} \cdot \frac{s_X}{s_Y}$$

4.3.2 Analyse de la Variance

$$e_t = y_t - \hat{y}_t \quad \text{On sait que : } \hat{y}_t = \hat{\beta}x_t$$

$$\sum_{t=1}^n y_t^2 = \sum_{t=1}^n (e_t + \hat{y}_t)^2 = \sum_{t=1}^n \hat{y}_t^2 + \sum_{t=1}^n e_t^2 + 2 \sum_{t=1}^n e_t \hat{y}_t$$

$$\begin{aligned} \sum_{t=1}^n e_t \hat{y}_t &= \sum_{t=1}^n (y_t - \hat{y}_t) \hat{\beta} x_t \\ &= \hat{\beta} \left[\sum_{t=1}^n (y_t - \hat{y}_t) x_t \right] \\ &= \hat{\beta} \left[\sum_{t=1}^n (\hat{y}_t - \hat{\beta} x_t) x_t \right] \\ &= \hat{\beta} \left[\sum_{t=1}^n y_t x_t - \hat{\beta} \sum_{t=1}^n x_t^2 \right] \\ &= \hat{\beta} \underbrace{\left[\sum_{t=1}^n y_t x_t - \hat{\beta} \sum_{t=1}^n x_t^2 \right]}_{=0} \end{aligned}$$

D'où $\boxed{\sum_{t=1}^n y_t^2 = \sum_{t=1}^n \hat{y}_t^2 + \sum_{t=1}^n e_t^2}$ EQ de l'analyse de la variance

$$\Leftrightarrow \underbrace{\sum_{t=1}^n (Y_t - \bar{Y})^2}_{\text{Variance totale}} = \underbrace{\sum_{t=1}^n (\hat{Y}_t - \bar{Y})^2}_{\text{Variance expliquée}} + \underbrace{\sum_{t=1}^n e_t^2}_{\text{Variance résiduelle}}$$

La fluctuation totale des valeurs de Y_t autour de la moyenne de l'échantillon peut être décomposée en deux éléments qui sont :

- **La variance expliquée** : Variation des valeurs de \hat{Y} autour de la moyenne. Somme des carrés expliquée par l'influence linéaire de X
- **La variance résiduelle** : Variation résiduelle des valeurs de Y autour de la droite des moindres carrés

4.3.3 Calcul du coefficient de détermination R^2

$$\sum_{t=1}^n y_t^2 = \sum_{t=1}^n \hat{y}_t^2 + \sum_{t=1}^n e_t^2 \quad \Leftrightarrow \quad \frac{\sum y_t^2}{\sum y_t^2} = \frac{\sum \hat{y}_t^2}{\sum y_t^2} + \frac{\sum e_t^2}{\sum y_t^2} \quad \Leftrightarrow \quad 1 = \frac{\hat{\beta}^2 \sum x_t^2}{\sum y_t^2} + \frac{\sum e_t^2}{\sum y_t^2}$$

Or : $r = \hat{\beta} \frac{\sqrt{\sum x_t^2}}{\sqrt{\sum y_t^2}}$ D'où :

$$\Leftrightarrow 1 = r^2 + \frac{\sum e_t^2}{\sum y_t^2}$$

$$\Leftrightarrow r^2 = 1 - \frac{\sum e_t^2}{\sum y_t^2}$$

$$\Leftrightarrow r^2 = 1 - \frac{\text{VR}}{\text{VT}} = \frac{\text{VE}}{\text{VT}}$$

Avec : $0 \leq r^2 \leq 1$

$$r^2 = \hat{\beta}^2 \frac{\sum x_t^2}{\sum y_t^2} \quad \text{Dans le cas d'une regression lineaire : } r_{xy} = \sqrt{r^2}$$

4.3.4 Test du coefficient de corrélation linéaire r

Statistique de test :

$$T(n-2) \sim \frac{\hat{\beta} - \beta}{\hat{\sigma}_\varepsilon} \cdot \sqrt{\sum x_t^2}$$

Rappel :

$$\hat{\beta} = r \cdot \frac{\sqrt{\sum y_t^2}}{\sqrt{\sum x_t^2}} \quad \text{et} \quad \hat{\sigma}_\varepsilon^2 = \frac{\sum e_t^2}{n-2}$$

D'où :

$$1 = r^2 + \frac{\sum e_t^2}{\sum y_t^2} \quad \Leftrightarrow \quad \sum_{t=1}^n e_t^2 = (1 - r^2) \sum_{t=1}^n y_t^2$$

Donc :

$$\hat{\sigma}_\varepsilon^2 = \frac{(1 - r^2) \sum y_t^2}{n - 2}$$

Posons $H_0 : \beta = 0$, sous H_0 :

$$T(n-2) \sim \frac{\hat{\beta}}{\hat{\sigma}_\varepsilon} \cdot \sqrt{\sum x_t^2} = r \cdot \frac{\sqrt{\sum y_t^2}}{\sqrt{\sum x_t^2}} \cdot \frac{\sqrt{\sum x_t^2}}{\sqrt{(1-r^2)} \sqrt{\sum y_t^2}} \cdot \sqrt{(n-2)}$$

$$T(n-2) \sim r \cdot \frac{\sqrt{n-2}}{\sqrt{1-r^2}}$$

Spécification du test

$$H_0 : \begin{matrix} \rho = 0 \\ \hat{\beta} = 0 \end{matrix} \quad H_1 : \rho \neq 0$$

Statistique de test

$$T(n-2) \sim r \cdot \frac{\sqrt{n-2}}{\sqrt{1-r^2}}$$

Intervalle d'acceptation

$$\begin{aligned} 1 - \alpha &= Prob \left[t_{\alpha/2} < T(n-2) < t_{1-\alpha/2} \right] \\ &= Prob \left[t_{\alpha/2} < r \cdot \frac{\sqrt{n-2}}{\sqrt{1-r^2}} < t_{1-\alpha/2} \right] \end{aligned}$$

$$= Prob \left[\left| r \cdot \frac{\sqrt{n-2}}{\sqrt{1-r^2}} \right| < t_{1-\alpha/2} \right]$$

RDD

Si $\left| r \cdot \frac{\sqrt{n-2}}{\sqrt{1-r^2}} \right| < t_{1-\alpha/2}$ on accepte H_0 au risque de α

Si $\left| r \cdot \frac{\sqrt{n-2}}{\sqrt{1-r^2}} \right| \geq t_{1-\alpha/2}$ on rejette H_0 au risque de α

4.3.5 Tableau de l'analyse de la variance

Origine des variations	\sum des carrés des écarts	DDL	Carrés moyens
VE	$Q_1 = \sum \hat{y}^2 = \hat{\beta}^2 \sum x_t^2$	1	$Q_1/1 = \sum \hat{y}^2$
VR	$Q_2 = \sum e_t^2$	$n-2$	$Q_2/n-2 = \hat{\sigma}_\varepsilon^2$
VT	$Q_3 = \sum y_t^2$	$n-1$	\times

Remarque : $Q_3 \simeq Q_1 + Q_2$

5 Test du coefficient de détermination R^2

Spécification du test

$$H_0 : \rho^2 = 0 \quad H_1 : \rho^2 \neq 0$$

Statistique de test

$$T(n-2) \sim \frac{r}{\sqrt{1-r^2}}$$

$$F_c = \frac{r^2}{1-r^2}(n-2) \sim F(1, n-2)$$

Intervalle d'acceptation

$$1 - \alpha = Prob \left[\frac{r^2}{1-r^2}(n-2) < F_{1-\alpha}(1, n-2) \right]$$

RDD

Si $F_c < F_{1-\alpha}(1, n-2)$ On accepte H_0 au risque de α

Si $F_c \geq F_{1-\alpha}(1, n-2)$ On rejette H_0 au risque de α

6 Utilisation du modèle de régression en prévision

6.1 Intervalle de confiance : de la valeur moyenne de Y connaissant une valeur donnée de X

X_0 : valeur donnée de X

$$Y_0 = \alpha + \beta X_0 + \varepsilon_0 \quad \hat{Y}_t = \hat{\alpha} + \hat{\beta} X_t \quad \Rightarrow \quad \hat{Y}_0 = \hat{\alpha} + \hat{\beta} X_0$$

On appelle valeur moyenne de Y connaissant une valeur donnée de X :

$$E(Y_0/X_0) = \alpha + \beta X_0$$

\hat{Y}_0 est un estimateur linéaire sans biais de $\alpha + \beta X_0$ et de $E(Y_0/X_0)$

$$E(\hat{Y}_0) = \alpha + \beta X_0 \quad E(\hat{Y}_0) = E(\hat{\alpha}) + E(\hat{\beta} X_0) = \alpha + \beta X_0$$

$$\hat{Y}_0 \sim N \left(\underbrace{E(\hat{Y}_0)}_{\alpha + X_0 \beta}, \underbrace{\sqrt{V(\hat{Y}_0)}}_{?} \right)$$

Calcul de $V(\hat{Y}_0)$

$$\begin{aligned} V(\hat{Y}_0) &= V(\hat{\alpha} + \hat{\beta} X_0) = V(\hat{\alpha}) + V(\hat{\beta} X_0) + 2 \text{Cov}(\hat{\alpha}, \hat{\beta} X_0) \\ &= V(\hat{\alpha}) + X_0^2 V(\hat{\beta}) + 2 \text{Cov}(\hat{\alpha}, \hat{\beta} X_0) \end{aligned}$$

Avec

$$\begin{aligned} V(\hat{\beta}) &= \frac{\sigma_\varepsilon^2}{\sum x_t^2} \\ V(\hat{\alpha}) &= \sigma_\varepsilon^2 \cdot \frac{\sqrt{\sum X_t^2}}{\sqrt{n \sum x_t^2}} = \sigma_\varepsilon^2 \cdot \left(\frac{\sum x_t^2 + n \bar{X}^2}{n \sum x_t^2} \right) = \sigma_\varepsilon^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{\sum x_t^2} \right) \\ \text{Cov}(\hat{\alpha}, \hat{\beta}) &= -\frac{\bar{X}}{\sum x_t^2} \cdot \sigma_\varepsilon^2 \end{aligned}$$

d'où

$$\begin{aligned} V(\hat{Y}_0) &= \sigma_\varepsilon^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{\sum x_t^2} \right) + X_0^2 \left(\frac{\sigma_\varepsilon^2}{\sum x_t^2} \right) + 2 X_0 \left(-\frac{\bar{X}}{\sum x_t^2} \cdot \sigma_\varepsilon^2 \right) \\ &= \sigma_\varepsilon^2 \left[\frac{1}{n} + \frac{\bar{X}^2 + X_0^2 - 2 X_0 \bar{X}}{\sum x_t^2} \right] \\ &= \sigma_\varepsilon^2 \left[\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_t^2} \right] \end{aligned}$$

$$\boxed{\hat{Y}_0 \sim N \left(\alpha + \beta X_0; \sigma_\varepsilon \sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_t^2}} \right)}$$

σ_ε Inconnu, d'où studentisation :

$$(n-2) \frac{\hat{\sigma}_\varepsilon^2}{\sigma_\varepsilon^2} \sim \chi^2(n-2) \quad \hat{Y}_0 \sim N \left(\alpha + \beta X_0; \sigma_\varepsilon \sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_t^2}} \right)$$

$$t_c = \frac{\frac{\hat{Y}_0 - (\alpha + \beta X_0)}{\sigma_\varepsilon \sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_t^2}}}}{\sqrt{\frac{n-2}{n-2} \cdot \frac{\hat{\sigma}_\varepsilon^2}{\sigma_\varepsilon^2}}} \sim T(n-2)$$

$$t_c = \frac{\hat{Y}_0 - (\alpha + \beta X_0)}{\hat{\sigma}_\varepsilon \sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_t^2}}} \sim T(n-2)$$

Intervalle de confiance :

$$\begin{aligned} 1 - \alpha &= Prob \left[t_{\alpha/2} \leq T(n-2) \leq t_{1-\alpha/2} \right] \\ &= Prob \left[t_{\alpha/2} \leq \frac{\hat{Y}_0 - (\alpha + \beta X_0)}{\hat{\sigma}_\varepsilon \sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_t^2}}} \leq t_{1-\alpha/2} \right] \\ &= Prob \left[\hat{Y}_0 - t_{1-\alpha/2} \cdot \hat{\sigma}_\varepsilon \sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_t^2}} \leq \alpha + \beta X_0 \leq \hat{Y}_0 - t_{\alpha/2} \cdot \hat{\sigma}_\varepsilon \sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_t^2}} \right] \\ &= Prob \left(\begin{pmatrix} \alpha + \beta X_0 \\ E(Y_0/X_0) \\ Y_0 \end{pmatrix} \in \left[\hat{Y}_0 \pm t_{\alpha/2} \cdot \hat{\sigma}_\varepsilon \sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_t^2}} \right] \right) \end{aligned}$$

6.2 Tests d'hypothèse : comparaison d'une prévision ponctuelle à la droite des moindres carrés

Calcul de la statistique de test :

- Calcul de $\sigma_{\hat{Y}_0}^2$

$$\begin{aligned} Y_0 &= \alpha + \beta X_0 \\ \hat{Y}_0 &= \hat{\alpha} + \hat{\beta} X_0 \\ Y_0 - \hat{Y}_0 &= \varepsilon_0 - (\hat{\alpha} - \alpha) - (\hat{\beta} - \beta) X_0 = Z_0 \end{aligned}$$

- Détermination de la loi de Z_0

$$\hat{Y}_0 \sim N \Rightarrow Z_0 \sim N(E(Z_0), \sigma_{Z_0})$$

– Espérance de Z_0 :

$$E(Z_0) = E(Y_0 - \hat{Y}_0) = E(\varepsilon) - \underbrace{E(\hat{\alpha} - \alpha)}_{=0} - \underbrace{E[(\hat{\beta} - \beta)X_0]}_{=0} = \underbrace{E(\varepsilon)}_{\text{Hypothèse de normalité}} = 0$$

\hat{Y}_0 est un ESB de Y_0

– Variance de Z_0

$$\begin{aligned}
V(Z_0) &= V[(\alpha + \beta X_0) - \hat{Y}_0] \\
&= V(\alpha + \beta X_0) + V(\hat{Y}) - \underbrace{\text{Cov}(\alpha + \beta X_0, \hat{Y}_0)}_{\substack{=0 \\ \text{Indépendance}}} \\
&= V(\varepsilon_0) + V(\hat{Y}_0) \\
&= \sigma_\varepsilon^2 + \sigma_\varepsilon^2 \left(\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_t^2} \right) \\
V(Z_0) &= \sigma_\varepsilon^2 \left(1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_t^2} \right)
\end{aligned}$$

Spécification du test

$$H_0 : \begin{cases} E(Y_0/X_0) \\ \alpha + \beta X_0 \\ Y_0 \end{cases} = \text{Constante} \quad H_1 : E(Y_0/X_0) \neq \text{Constante}$$

Statistique de test

$$t_c = \frac{Y_0 - \hat{Y}_0}{\hat{\sigma}_\varepsilon \sqrt{1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_t^2}}} \sim T(n-2)$$

Intervalle d'acceptation

$$\begin{aligned}
1 - \alpha &= \text{Prob} [t_{\alpha/2} < T(n-2) < t_{1-\alpha/2}] \\
&= \text{Prob} \left[t_{\alpha/2} < \frac{Y_0 - \hat{Y}_0}{\hat{\sigma}_\varepsilon \sqrt{1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_t^2}}} < t_{1-\alpha/2} \right] \\
&= \text{Prob} \left[\hat{Y}_0 \in \left(\begin{pmatrix} \alpha + \beta X_0 \\ E(Y_0/X_0) \\ Y_0 \end{pmatrix} \pm \begin{pmatrix} t_{\alpha/2} \\ t_{1-\alpha/2} \end{pmatrix} \hat{\sigma}_\varepsilon \sqrt{1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_t^2}} \right) \right]
\end{aligned}$$

RDD

Si $\hat{Y}_0 \in \text{IA}$ on accepte H_0 au risque de α

Si $\hat{Y}_0 \notin \text{IA}$ on rejette H_0 au risque de α

7 Le modèle linéaire simple à plusieurs variables explicatives

7.1 Les estimateurs des moindres carrés ordinaires (MCO)

7.1.1 Spécifications matricielles du modèle

7.1.2 Les hypothèses de base du MLGS

7.1.3 Les estimateurs des moindres carrés ordinaires

7.1.4 Les propriétés des estimateurs des moindres carrés ordinaires

7.2 Test des estimateurs

7.3 L'analyse de la variance et test du coefficient de détermination

7.4 Utilisation du modèle en prévision

Part II

Modèle linéaire général à k paramètres estimés

Ici nous supposons que les hypothèses de base sur l'aléa ne sont plus vérifiées, à savoir : normalité, auto-corrélation, homoscedasticité, hétéroscedasticité.

8 Test de normalité

Il existe deux tests de normalité :

- Test de Skewness (symétrie)
- Kurtosis (aplatissement)

La normalité concerne l'aléa, comme on ne connaît pas l'aléa, on fait les tests sur les résidus.

8.1 Test de symétrie normale (Skewness)

Spécification du test

H_0 : symétrie normale (Skewness)

Statistique de test

$\beta_1^{1/2}$: Coefficient de symétrie de Pearson (Skewness)

μ_k : Moment centré d'ordre k

$$\beta_1^{1/2} = \frac{\mu_3}{\mu_2^{3/2}} \sim N\left(0, \sqrt{\frac{6}{n}}\right)$$

d'où

$$v_1 = \frac{\beta_1^{1/2} - 0}{\sqrt{\frac{6}{n}}} \sim N(0, 1)$$

Intervalle d'acceptation

$$1 - \alpha = Prob \left[u_{\alpha/2} < \frac{\beta_1^{1/2} - 0}{\sqrt{\frac{6}{n}}} < u_{1-\alpha/2} \right]$$

RDD

Si $\left| \frac{\beta_1^{1/2} - 0}{\sqrt{\frac{6}{n}}} \right| < u_{1-\alpha/2}$ On accepte H_0 au risque de α . (Il y a symétrie normale)
Si $\left| \frac{\beta_1^{1/2} - 0}{\sqrt{\frac{6}{n}}} \right| \geq u_{1-\alpha/2}$ On rejette H_0 au risque de α

8.2 Test d'aplatissement normal (Kurtosis)

Spécification du test

H_0 : Aplatissement normal

Statistique de test β_2 : Coefficient de Kurtosis

$$\beta_2 = \frac{\mu_4}{\mu_2^2} \sim N \left(3, \sqrt{\frac{24}{n}} \right)$$

d'où

$$v_2 = \frac{\beta_2 - 3}{\sqrt{\frac{24}{n}}} \sim N(0, 1)$$

Intervalle d'acceptation

$$1 - \alpha = Prob \left[u_{\alpha/2} < \frac{\beta_2 - 3}{\sqrt{\frac{24}{n}}} < u_{1-\alpha/2} \right]$$

RDD

Si $\left| \frac{\beta_2 - 3}{\sqrt{\frac{24}{n}}} \right| < u_{1-\alpha/2}$ On accepte H_0 au risque de α . (Il y a aplatissement normale)
Si $\left| \frac{\beta_2 - 3}{\sqrt{\frac{24}{n}}} \right| \geq u_{1-\alpha/2}$ On rejette H_0 au risque de α

Si les deux hypothèses sont validées (symétrie et aplatissement normal) alors il y a normalité de l'aléa

8.3 Test de Jarque-Bera

Spécification du test

H_0 : Normalité

Statistique de test

$$JB = \frac{n}{6}\beta_1 + \frac{n}{24}(\beta_2 - 3)^2 \sim \chi^2(2)$$

Intervalle d'acceptation

$$1 - \alpha = Prob \left[\frac{n}{6}\beta_1 + \frac{n}{24}(\beta_2 - 3)^2 < \chi^2_{1-\alpha}(2) \right]$$

RDD

Si $JB < \chi^2_{1-\alpha}(2)$ On accepte H_0 au risque de α (Il y a normalité des résidus)

Si $JB \geq \chi^2_{1-\alpha}(2)$ On rejette H_0 au risque de α

9 Le problème de l'autocorrélation des erreurs

9.1 Détection de l'autocorrélation

Comme l'aléa (ε_t) est inconnu, le test se fait sur les résidus $e_t = Y_t - \hat{Y}_t$. **Autocorrélation** : On analyse la corrélation à l'intérieur de la distribution des résidus. Il y aura autocorrélation toutes les fois où l'on peut trouver un coefficient de corrélation linéaire significativement différent de 0 entre la chronique des résidus et elle-même décalée d'un ou de plusieurs pas de temps.

Dessin coef autocorrelation*

On va appeler r_k le coefficient d'autocorrélation à l'ordre k (on mesure la corrélation entre la chronique et e_t)

Corrélogramme : représentation graphique de l'ensemble des coefficients de corrélation graph FAC

Il existe 2 types d'autocorrélation.

graph AC

9.2 Causes de l'autocorrélation

1. Le modèle ignore une variable exogène.
2. Les variables de départ ont mal été désaisonnalisées (donnée de départ saisonnière)
3. Les variables de départ possédaient des non informations et corrigés par extrapolation linéaire)
4. Les valeurs de départ contiennent des événements exceptionnels mal expliqués par le modèle. Cela peut signifier qu'il y a eu un manque de variable dichotomique ($= \{0; 1\}$)
5. Les variables de départ ne sont pas stationnaire, elles peuvent contenir

Graph

9.3 Les effets de l'autocorrélation

- Les estimateurs sont sans biais
- Les variances d'échantillon des coefficients de régression ne sont plus minimales (les estimateurs ne sont plus efficaces)

- On ne peut pas utiliser le modèle pour faire la prévision, la méthode des MCO n'est plus la meilleure des méthodes pour estimer le modèle (remise en cause du modèle)

9.4 Tests d'autocorrélation

9.4.1 Test d'autocorrélation d'ordre 1 (Durbin Watson)

Le test de Durbin Watson permet de mettre en évidence l'autocorrélation à l'ordre 1.

Il y a processus d'AR(1) lorsque :

$$\varepsilon_t = \rho \varepsilon_{t-1} + \eta_t$$

$\eta_t \sim$ Bruit Blanc : Hypothèse de normalité, homosélasticité, non autocorrélation.

Spécification du test :

$$H_0 : \rho = 0 \quad H_1 : \rho \neq 0$$

$\rho = 0 \Rightarrow$ Absence d'autocorrélation car : $\varepsilon_t = 0\varepsilon_{t-1}$

Statistique de test :

$$DW = \frac{\sum (e_{t+1} - e_t)^2}{\sum e_t^2}$$

RDD

$0; d_1$	$d_1; d_2$	2	$4 - d_2; 4 - d_1$	$4 - d_1; 4$
autocorrélation positive d'ordre 1	Zone de doute ←	Absence d'autocorrélation (H0 vrai)	Zone de doute →	autocorrélation négative d'ordre 1

Remarque :

$$DW \xrightarrow{n \rightarrow \infty} 2(1 - \bar{\rho})$$

Où $\hat{\rho}$ est un estimateur de ρ tel que : $\hat{\rho} = \frac{\sum (e_{t+1} - e_t)^2}{\sum e_t^2}$ avec $|\rho| < 1$

9.4.2 Test d'autocorrélation d'ordre k

Statistique de Ljung-Box

$$\varepsilon_t = \rho_1 \varepsilon_{t-1} + \rho_2 \varepsilon_{t-2} + \dots + \rho_k \varepsilon_{t-k} + \eta_t$$

Spécification du test :

$$H_0 : \rho_1 = \rho_2 = \dots = \rho_k \quad H_1 : \text{au moins un coef} \neq 0$$

Statistique de test :

$$Q_{\text{stat}}(K) = n(n+2) \sum_{k=1}^k \frac{r_k^2}{n-k} \sim \chi_{1-\alpha}^2(K)$$

Statistique à l'ordre 3 :

$$\begin{aligned} Q_{\text{stat}}(3) &= n(n+2) \sum_{k=1}^3 \frac{\hat{r}_k^2}{n-k} \\ &= n(n+2) \left(\frac{r_1^2}{n-1} + \frac{r_2^2}{n-2} + \frac{r_3^2}{n-3} \right) \end{aligned}$$

RDD : Si $Q_{\text{stat}} < \chi_{1-\alpha}^2(K)$ On accepte H_0 au risque de α (absence d'AR à l'ordre k)
 Si $Q_{\text{stat}} \geq \chi_{1-\alpha}^2(K)$ On rejette H_0 au risque de α (AR à l'ordre k)

10 Le problème de l'hétéroscédasticité

10.1 Définition et conséquences

Il y a hétéroscédasticité lorsque les termes qui se trouvent sur la diagonale de la matrice covariance-variance sont différents entre eux tel que : $E(\varepsilon_1^2) = \sigma_1^2 \neq E(\varepsilon_2^2) = \sigma_2^2 \neq E(\varepsilon_n^2) = \sigma_n^2$
 Les conséquences de l'hétéroscédasticité sont les mêmes que celles de l'autocorrélation (l'hétéroscédasticité étant un cas particulier de l'autocorrélation).

10.2 Test de Glejser

Le test de Glejser consiste à regresser la valeur absolue des résidus (obtenus lors de la regression) avec chacune des variables explicatives (Il y a donc autant de regressions qu'il y a de variables explicatives).

$$\begin{aligned} |e_t| &= a_0 + a_1 + X_{kt} \\ |e_t| &= a_0 + \frac{a_1}{X_{kt}} \\ |e_t| &= a_0 + a_1 \sqrt{X_{kt}} \\ |e_t| &= a_0 + \frac{a_1}{\sqrt{X_{kt}}} \end{aligned}$$

On teste par la suite la signification de a_1 .

Spécification du test :

$$H_0 : a_1 = 0 \quad H_1 : a_1 \neq 0$$

Statistique de test :

$$t_c = \frac{\hat{a}_1}{\hat{\sigma}_{\hat{a}_1}} \sim T(n-2)$$

RDD : Si $|t_c| < t_{1-\alpha/2}$ On accepte H_0 au risque de α (homoscédasticité)
 Si $|t_c| \geq t_{1-\alpha/2}$ On rejette H_0 au risque de α (hétéroscédasticité)

10.3 Test de ARCH

Processus autorégressif sur le carré de la variable :

$$\varepsilon_t^2 = \varphi_1 \varepsilon_{t-1}^2 + \varphi_2 \varepsilon_{t-2}^2 + \dots + \varphi_p \varepsilon_{t-p}^2 + \eta_t$$

Spécification du test

$$H_0 : \varphi_1 = \varphi_2 = \dots = \varphi_p = 0 \quad H_1 : \text{au moins un coef} \neq 0 \quad (1)$$

Statistique de test : Multiplicateur de Lagrange

$$LM = nR^2 \sim \chi_{1-\alpha}^2(p)$$

Où p est le nombre de retards.

RDD :

Si $nR^2 < \chi_{1-\alpha}^2(p)$ On accepte H_0 au risque de α (homoscédasticité)

Si $nR^2 \geq \chi_{1-\alpha}^2(p)$ On rejette H_0 au risque de α (hétéroscédasticité)

NOTES 08/11/21

10.4 Test de Breusch Pagan

Si il y a hétéroscédasticité, il y a une relation entre l'aléa et les variables explicatives.

$$\varepsilon_t^2 = \delta_1 + \delta_2 X_{2t} + \dots + \delta_k X_{kt} + \nu_t$$

Spécification du test :

$$H_0 : \delta_1 = \delta_2 = \dots = \delta_k = 0 \quad H_1 : \text{au moins un coef} \neq 0$$

Deux façons de procéder :

Statistique de test : Fischer

$$F_c = \frac{R^2}{1 - R^2} \cdot \frac{n - K}{K - 1} \sim F_{1-\alpha}(K - 1, n - K)$$

RDD :

Si $F_c < F_{1-\alpha}(K - 1, n - K)$ On accepte H_0

Si $F_c \geq F_{1-\alpha}(K - 1, n - K)$ On rejette H_0

Statistique de test : Lagrange

$$LM = nR^2 \sim \chi_{1-\alpha}^2(K - 1)$$

RDD :

Si $nR^2 < \chi_{1-\alpha}^2(K - 1)$ On accepte H_0

Si $nR^2 \geq \chi_{1-\alpha}^2(K - 1)$ On rejette H_0

Où K est le nombre de paramètres estimés.

10.5 Test de White

Le test de White est fondé sur une relation entre le carré des résidus et une ou plusieurs variables explicatives au carré au sein d'une même régression.

On peut réaliser le test de white sans termes croisés et avec termes croisés. Pour le premier :

$$\varepsilon_t^2 = a_0 + a_1 x_{1t} + b_1 x_{1t}^2 + a_2 x_{2t} + b_2 x_{2t}^2 + \dots + a_k x_{kt} + b_k x_{kt}^2 + \eta_t$$

Spécification du test :

$$H_0 : a_1 = b_1 = a_2 = b_2 = \dots = a_k = b_k \quad H_1 : \text{au moins un coef} \neq 0$$

Statistique de test : Fischer

$$F_c = \frac{R^2}{1-R^2} \cdot \frac{n-K}{K-1} \sim F_{1-\alpha}(K-1, n-K)$$

RDD :

Si $F_c < F_{1-\alpha}(K-1, n-K)$ On accepte H_0

Si $F_c \geq F_{1-\alpha}(K-1, n-K)$ On rejette H_0

Statistique de test : Lagrange

$$LM = nR^2 \sim \chi^2_{1-\alpha}(K-1)$$

RDD :

Si $nR^2 < \chi^2_{1-\alpha}(K-1)$ On accepte H_0

Si $nR^2 \geq \chi^2_{1-\alpha}(K-1)$ On rejette H_0

Où K est le nombre de paramètres estimés.

Avec termes croisés :

$$\varepsilon_t^2 = \lambda_1 + \lambda_2 X_{2t} + \dots + \lambda_k X_{kt} + a_2 X_{2t}^2 + a_k X_{kt}^2 + \mu_t + b_2 X_{2t} X_{3t} + b_3 X_{2t} X_{4t} + \eta_t$$

La manière de procéder est la même que en terme non croisés.

10.6 Goldfeld - Quandt

Ce test se construit toutes les fois où l'écart type de l'erreur du modèle s'accroît proportionnellement avec l'une des variables explicative

$$\sqrt{E(\varepsilon_t^2)} = aX_{kt} + \eta_t$$

On ordonne les observations des variables Y et X_{kt} en fonction des valeurs croissantes de la variable qui a une relation avec l'écart type de l'alea. On supprime les observations centrales de l'échantillon obtenu et on appelle m le nombre de ces observations supprimées.

$$n = 30$$

$$m = 8$$

$$n = 60$$

$$m = 16$$

On obtient deux sous échantillons, un qui correspond aux faibles valeurs des variables explicatives, et l'autre qui correspond aux fortes de celle ci, On régresse en appliquant les MCO sur chacun de ces sous échantillons et l'on calcule les SCR de ces deux échantillons SCR_1 et SCR_2 .

Spécification du test :

H_0 : Homoscédasticité

H_1 : Hétéroscédasticité

Statistique de test :

$$F_c = \frac{SCR_2}{SCR_1} \sim F_{1-\alpha} \left(\frac{n-m}{2} - k; \frac{n-m}{2} - k \right)$$

RDD :

Si $F_c < F_{1-\alpha}$ On accepte H_0 au risque de α (homosédasticité)

Si $F_c \geq F_{1-\alpha}$ On rejette H_0 au risque de α (heterosedasticité)

11 La Multi-colinéarité

11.1 Definition

Dans le MLS on a supposé que les variables X_k étaient linéairement indépendantes, ce que l'on a traduit par le fait que le rang de X est égal à k .

On dira qu'il y a colinéarité parfaite entre deux variables explicatives si les deux vecteurs d'observation sont identiques, ce que l'on traduit par le coefficient de corrélation linéaire entre les deux égal à 1.

On dira qu'il y a multicollinéarité parfaite entre plusieurs variables (explicatives) si il existe une combinaison linéaire des observations de plusieurs variables qui donnent le vecteur des observations d'une autre variable. Le coefficient de détermination (multiple) R^2 entre ces variables doit être égal à 1.

Dans le cas de colinéarité parfaite il est nécessaire de modifier le modèle de départ en supprimant la variable qui est à l'origine de la colinéarité.

Dans la pratique la colinéarité parfaite n'existe quasiment pas, par contre il y a une tendance vers la colinéarité, c'est à dire un $R^2 \rightarrow 1$.

11.2 Les effets de la colinéarité

1. Les estimateurs des MC tendent à être très important en valeur absolue
2. Les variances et les covariances tendent à être importantes

11.3 Les tests de colinéarité

11.3.1 Test d'Haitvosky

Ce test repose sur l'observation de la matrice des coefficients de corrélation linéaire simple **entre les variables explicatives**. Cette matrice permet de détecter des colinéarités simples mais pas des multi-colinéarités.

\tilde{R} matrice des coefficients de corrélation linéaire simple entre les variables explicatives.

Si un élément de cette matrice tend vers 1, cela veut dire qu'il existe une colinéarité entre les deux variables exogènes utilisées dans le calcul de ce coefficient.:

Spécification du test :

$$H_0 : |\tilde{R}| = 0$$

$$H_1 : |\tilde{R}| \neq 0$$

Statistique de test :

$$H = - \left(n - 1 - \frac{1}{6}(2k + 5) \right) \ln \left(1 - |\tilde{R}| \right) \sim \chi^2_{1-\alpha} \left(\frac{1}{2}k(k-2) \right)$$

RDD :

Si $H < \chi^2_{1-\alpha} \left(\frac{1}{2}k(k-2) \right)$ On accepte H_0 au risque de α

Si $H \geq \chi^2_{1-\alpha} \left(\frac{1}{2}k(k-2) \right)$ On rejette H_0 au risque de α

11.3.2 VIF

Facteur d'inflation de la variance

$$VIF_i = \frac{1}{1 - R_i^2}$$

R_i^2 : coefficient de détermination multiple entre une variable X_i et les autres

$$\begin{aligned} \text{VIF}_1 &= \frac{1}{1 - R_1^2} & R_1^2 &\rightarrow X_2 \text{ et } X_3, X_4 \\ \text{VIF}_2 &= \frac{1}{1 - R_2^2} & R_2^2 &\rightarrow X_3 \text{ et } X_2, X_4 \\ \text{VIF}_3 &= \frac{1}{1 - R_3^2} & R_3^2 &\rightarrow X_4 \text{ et } X_2, X_3 \end{aligned}$$

$\text{VIF} \rightarrow +\infty$ Cela veut dire qu'il y a de la colinéarité entre X_i et les autres variables.

11.3.3 Etude des valeurs propres de la matrice des coefficients de corrélation linéaire simple \tilde{R}

Pour réaliser le test sur les valeurs propres, il suffit de calculer les valeurs propres de la matrice des coefficients de corrélation (linéaire entre les variables explicatives).

$$|\tilde{R} - \lambda I| = 0 \rightarrow \lambda_i$$

Il revient par la suite de comparer les valeurs propres. Si l'on a un écart relativement important entre les valeurs propres alors il y a colinéarité dans le modèle. A l'inverse, si les valeurs propres sont identiques, il y a absence de colinéarité. Exemple :

$$\begin{aligned} \lambda_1 = 0.2; \lambda_2 = 1.8 &\Rightarrow \text{Colinéarité} \\ \lambda_1 = 0.5; \lambda_2 = 0.6 &\Rightarrow \text{Absence de colinéarité} \end{aligned}$$

11.4 Solutions aux violations des hypothèses de base

Dans un modèle linéaire simple, si il y a de l'hétéroscédasticité, autocorrélation, et colinéarité on peut apporter des solutions.

- **En cas d'hétéroscédasticité** : Si l'on connaît la variable à l'origine de l'hétéroscédasticité on peut corriger en supprimant la variable (ex: diviser par cette variable)
- **En cas de quasi colinéarité** : On peut utiliser la méthode de la Ridge Trace avec le calcul des estimateurs Ridge.

$$\begin{aligned} \hat{\beta} &= (X'X)^{-1} X'Y \\ \hat{\beta}' &= (X'X + kI)^{-1} X'Y \quad (\text{estimateur Ridge}) \end{aligned}$$

Graph Ridge

- **En cas d'autocorrélation** :
 - Même méthode que pour l'hétéroscédasticité.
 - Méthode des estimateurs de Aiken, (calcul à partir de la matrice des variances covariances) $\tilde{\beta} = [X'\Omega^{-1}X]^{-1} [X'\Omega Y]$

11.5 Robustesse du modèle

On dira qu'un modèle est robuste lorsqu'il est valide dans des circonstances différentes. On scinde le modèle en deux sous périodes (il faut au préalable qu'il y ait un événement majeur qui change la chronique, par exemple un attentat).

Un modèle est donc dit robuste si quels que soient les sous ensembles constitués à partir d'observations consécutives (sur la période de 1 à n), les estimateurs du même modèle sur chacune des sous périodes sont :

1. Valides sur le plan statistique :
 - Test individuel de significativité ($H_0 : \beta_j = 0$)
 - Test de validité globale ($H_0 : \rho^2 = 0$)
 - Tests sur les résidus :
 - Test de normalité
 - Test d'autocorrélation
 - Test d'hétéroscédasticité
2. Sont stables (les paramètres ne sont pas significativement différents entre eux)

11.5.1 Test d'ANACOVA

SCR_0 : Somme des carrés des résidus du modèle sur toute la période.

SCR_1 : Somme des carrés des résidus du premier sous ensemble.

SCR_2 : Somme des carrés des résidus du second sous ensemble.

$$SCR_1 + SCR_2 = SCR_a \quad SCR_0 > SCR_a$$

Spécification du test :

$H_0 : \beta_j^1 = \beta_j^2$ Coefficient de première période = coefficient de seconde période (stabilité)

$H_1 : \beta_j^1 \neq \beta_j^2$

Statistique de test :

$$F_c = \frac{SCR_0 - SCR_a}{SCR_a} \cdot \frac{n - 2k}{k} \sim F_{1-\alpha}(k, n - 2k)$$

n : Nombre total sur la chronique

k : Nombre totale de paramètres estimés

RDD :

Si $< F_{1-\alpha}(k, n - 2k)$ On accepte H_0 au risque de α (stabilité)

Si $\geq F_{1-\alpha}(k, n - 2k)$ On rejette H_0 au risque de α (non stable)

11.5.2 Test de comparaison des coefficients de régression

Spécification du test :

$H_0 : \beta_j^1 = \beta_j^2 \Leftrightarrow \beta_j^1 - \beta_j^2 \Leftrightarrow d_j = 0$

$H_1 : \beta_j^1 \neq \beta_j^2$

Statistique de test :

$$t_c = \frac{\hat{d}_j}{\hat{\sigma}_{\hat{d}_j}} = \frac{\hat{\beta}_j^1 - \hat{\beta}_j^2}{\sqrt{s^2(\hat{\beta}_j^2) + s^2(\hat{\beta}_j^2)}} \sim T_{1-\alpha/2}(n_1 + n_2 - 2k) = T_{1-\alpha/2}(n - 2k)$$

Avec : $\hat{\sigma}_{\hat{d}_j}^2 = s^2[\hat{\beta}_j^1 - \hat{\beta}_j^1] = s^2(\hat{\beta}_j^1) + s^2(\hat{\beta}_j^2)$

RDD :

Si $|t_c| < T_{1-\alpha/2}(n - 2k)$ On accepte H_0 au risque de α

Si $|t_c| \geq T_{1-\alpha/2}(n - 2k)$ On rejette H_0 au risque de α

11.5.3 Test de comparaison des coefficients de corrélation

On teste ici si les coefficients de corrélation sont sensiblement égaux. Un coefficient de corrélation ne suit pas une distribution d'expressions simple autour de son espérance mathématique, car la distribution est fortement asymétrique pour des valeurs éloignées de 0.

$$z = \operatorname{argth} r = \frac{1}{2} \ln \frac{1+r}{1-r}$$

argth : Argument tangent hyperbolique.

Remarque : Ici les hypothèses du test portent sur les valeurs théoriques.

$$\begin{aligned} z_1 &= \operatorname{argth} r_1 = \frac{1}{2} \ln \frac{1+r_1}{1-r_1} & z'_1 &= \operatorname{argth} \rho_1 = \frac{1}{2} \ln \frac{1+\rho_1}{1-\rho_1} \\ z_2 &= \operatorname{argth} r_2 = \frac{1}{2} \ln \frac{1+r_2}{1-r_2} & z'_2 &= \operatorname{argth} \rho_2 = \frac{1}{2} \ln \frac{1+\rho_2}{1-\rho_2} \\ d &= z_1 + z_2 & d' &= \rho_1 + \rho_2 \end{aligned}$$

Spécification du test :

$H_0 : z'_1 = z'_2 \Leftrightarrow z'_1 - z'_2 = 0 \Leftrightarrow \mathbf{d}' = \mathbf{0}$

$H_1 : z'_1 \neq z'_2$

Statistique de test :

$$t_c = \frac{d}{\hat{\sigma}_d} = \frac{z_1 - z_2}{\sqrt{V(z_1) + V(z_2)}} = \frac{\frac{1}{2} \ln \frac{1+r_1}{1-r_1} - \frac{1}{2} \ln \frac{1+r_2}{1-r_2}}{\sqrt{\frac{1}{n_1-3} + \frac{1}{n_2-3}}} \sim T_{1-\alpha/2}(n_1 + n_2 - 2k) = T_{1-\alpha/2}(n - 2k)$$

Avec : $V(d) = V(z_1) + V(z_2)$ où $V(z_i) = \frac{1}{n_i-3}$

RDD :

Si $|t_c| < T_{1-\alpha/2}(n - 2k)$ On accepte H_0 au risque de α

Si $|t_c| \geq T_{1-\alpha/2}(n - 2k)$ On rejette H_0 au risque de α

Part III

Bibliographie

- Bourbonnais - Econométrie - Dunod

- Johnston Dinardo - Econométrie
- Greene - Econométrie - Pearson